

Rapport de stage

Mise en place d'un service de
compilation/d'exécution isolé pour la plateforme
PLM dédiée à l'apprentissage de la programmation

Tanguy GLOAGUEN

Année 2014–2015

Déclaration sur l'honneur de non-plagiat

Je soussigné(e),

Nom, prénom : GLOAGUEN, Tanguy

Élève-ingénieur(e) régulièrement inscrit(e) en 2^e année à TELECOM Nancy

Numéro de carte de l'étudiant(e) : 31313847

Année universitaire : 2014–2015

Auteur(e) du document, mémoire, rapport ou code informatique intitulé :

Mise en place d'un service de compilation/d'exécution isolé pour la plateforme PLM dédiée à l'apprentissage de la programmation

Par la présente, je déclare m'être informé(e) sur les différentes formes de plagiat existantes et sur les techniques et normes de citation et référence.

Je déclare en outre que le travail rendu est un travail original, issu de ma réflexion personnelle, et qu'il a été rédigé entièrement par mes soins. J'affirme n'avoir ni contrefait, ni falsifié, ni copié tout ou partie de l'œuvre d'autrui, en particulier texte ou code informatique, dans le but de me l'accaparer.

Je certifie donc que toutes formulations, idées, recherches, raisonnements, analyses, programmes, schémas ou autre créations, figurant dans le document et empruntés à un tiers, sont clairement signalés comme tels, selon les usages en vigueur.

Je suis conscient(e) que le fait de ne pas citer une source ou de ne pas la citer clairement et complètement est constitutif de plagiat, que le plagiat est considéré comme une faute grave au sein de l'Université, et qu'en cas de manquement aux règles en la matière, j'encourrais des poursuites non seulement devant la commission de discipline de l'établissement mais également devant les tribunaux de la République Française.

Fait à Nancy, le 24 août 2015

Signature :

Rapport de stage

Mise en place d'un service de
compilation/d'exécution isolé pour la plateforme
PLM dédiée à l'apprentissage de la programmation

Tanguy GLOAGUEN

Année 2014–2015

Tanguy GLOAGUEN
tanguy.gloaguen@telecomnancy.eu

TELECOM Nancy
193 avenue Paul Muller,
CS 90172, VILLERS-LÈS-NANCY
+33 (0)3 83 68 26 00
contact@telecomnancy.eu

LORIA
Campus Scientifique
54506, Nancy



Encadrants : Martin QUINSON, Gérald OSTER

Remerciements

Je tiens tout d'abord à remercier mes encadrants de stage, MM. Oster et Quinson, pour leur accueil au sein de leur équipe, leurs conseils et explications sur le système à étudier et le temps qu'ils ont accordé à l'étude des modèles proposés.

Je remercie également Matthieu Nicolas, qui m'a également encadré lors de ce stage, pour son aide précieuse sur les outils à utiliser, mais aussi pour son écoute et ses conseils quant aux méthodes de résolution des problèmes étudiés.

Enfin, je remercie mes collègues de bureau, MM. Bühler, Carpentier et Grguric, pour leurs aides sur la réalisation et pour l'ambiance agréable de travail.

Table des matières

Remerciements	v
Table des matières	vii
1 Présentation	3
1.1 Le LORIA	3
1.2 La "Programmer's Learning Machine"	4
1.2.1 La PLM en tant qu'application lourde	4
1.2.2 Portage web de la PLM	5
2 Problématique du stage	7
2.1 Contexte du stage	7
2.2 Objectifs du stage	7
3 Réalisation	9
3.1 Environnement de réalisation	9
3.2 Méthode de réalisation	9
3.2.1 Modèle global envisagé	9
3.2.2 Création des juges	10
3.2.3 Utilisation des juges	10
3.2.4 Etude d'un mode debug	12
3.2.5 Utilisation de Docker	13
3.2.6 Documentation du code existant	13
3.2.7 Ajout d'opérations de logging	13
3.2.8 Standardisation des données	13
3.2.9 Pré-génération des données	14
3.2.10 Nettoyage de la PLM	14
3.2.11 Mise en place d'un Security Manager	15
3.3 Résultats obtenus	15

3.3.1	Modèle final	15
3.3.2	Apports	16
4	Résultats	19
4.1	Bilan	19
4.2	Améliorations prévues	19
4.3	Améliorations possibles	19
	Résumé	21
	Abstract	21

Introduction

L'enseignement classique est celui généralement utilisé aujourd'hui, mais l'accès au public de l'informatique a permis de mettre en place des apprentissages plus automatisés : outils d'aide à l'enseignement, MOOC (cours en ligne) mais aussi logiciels d'apprentissage autonome. C'est dans ce contexte que se place la Programmer's Learning Machine : depuis 2007, cette application permet de standardiser les enseignements de base en programmation ainsi que d'aider les enseignants à évaluer les progrès des élèves. La PLM a pour but d'enseigner les bases de la programmation et de fournir aux étudiants les meilleurs outils possibles pour apprendre à coder.

En vue de moderniser le logiciel, il a été récemment proposé de transformer l'application PLM en un outil en ligne. Cette modification a entraîné des contraintes de sécurité, de puissance du matériel, de consommation mémoire et processeur des services et de mise à l'échelle supplémentaires qu'il a fallu résoudre.

L'objectif de ce stage était de proposer des solutions à ces contraintes, de les implémenter et de proposer des méthodes de déploiement.

Dans un premier temps, nous verrons le contexte du stage plus en détail : l'établissement d'accueil mais aussi la Programmer's Learning Machine en tant qu'application et qu'interface web.

Dans un second temps, nous verrons les objectifs du stage.

Puis, nous étudierons la réalisation de ces objectifs en tant que méthodologie, en tant qu'environnement et les résultats obtenus.

Enfin, nous ferons un bilan des résultats et une liste des améliorations prévues et possibles.

1 Présentation

1.1 Le LORIA

Le Laboratoire Lorrain de Recherche en Informatique et ses Applications (abrégé LORIA) est une Unité Mixte de Recherche créée en 1997 par association entre le CNRS (Centre National de la Recherche Scientifique), l'UL (Université de Lorraine) et l'INRIA (Institut National de Recherche en Informatique et Automatique).

La mission principale du LORIA est la recherche fondamentale et appliquée dans le cadre des sciences informatiques. Elle accueille un total de 450 personnes ¹, réparties en 27 équipes sur 5 départements :

Algorithmique, calcul, image et géométrie

Ce département de 6 équipes, dirigé par Sylvain Lazard, s'intéresse principalement aux algorithmes tout en gardant une différence sur les applications selon les équipes.

Méthodes formelles

Ce département de 6 équipes, dirigé par Dominique Méry, développe des contributions aux logiques et théories de preuves. C'est dans ce département que se trouve VERIDIS et le projet PLM.

Réseaux, systèmes et services

Département de 3 équipes dirigé par Ye-Quiong Song, il s'intéresse principalement aux problèmes issus des systèmes distribués et parallèles.

Traitement des langues et des connaissances

Ce département de 8 équipes dirigé par Bruno Guillaume porte sur l'étude des langues naturelles, des connaissances et des documents.

Systèmes complexes et intelligence artificielle

Département de 5 équipes dirigé par Bernard Girau, il s'occupe des méthodes d'apprentissage, d'analyse et de prise de décision rendus possibles par les intelligences artificielles.

1. chiffres 2014, <http://www.loria.fr/rapports-activite-2/rapport-dactivite-2014>

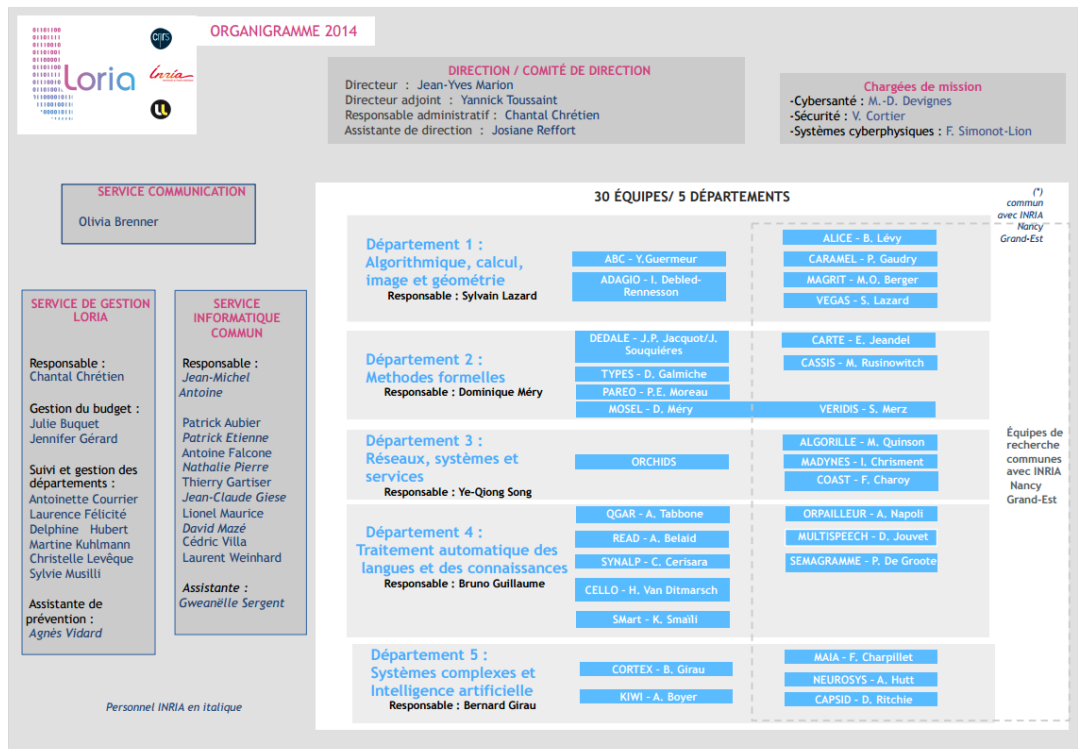


FIGURE 1.1 – Organigramme du LORIA

En tant qu'UMR, le LORIA possède sa propre administration. Un organigramme du LORIA est disponible en 1.1, présentant la structure interne. On y remarque que même si les différentes entités administratives sont bien définies, il n'y a pas de hiérarchie directe entre elles.

1.2 La "Programmer's Learning Machine"

Le projet "Programmer's Learning Machine" (abrégé PLM) est un projet commencé en 2007 par Martin Quinson et G rald Oster.

Ce projet a pour but de fournir aux  tudiants en informatique une plateforme d'initiation aux concepts de programmation basiques et avanc es ainsi qu'un outil d'analyse et d'aide   la m diation pour l'enseignant. La PLM est utilis e depuis   Telecom Nancy, et sert en premi re ann e   aider   la formation des nouveaux  tudiants. Elle poss de pour le moment plus de 200 exercices distincts portant sur divers sujet allant de l'introduction aux concepts de programmation   la r cursivit  ou aux tris.

1.2.1 La PLM en tant qu'application lourde

Dans sa forme originelle, la PLM  tait une application Java lourde  crite en Swing. L'utilisateur lan ait le programme sur son ordinateur et obtenait des r sultats. L'application lourde est aujourd'hui en version 2.6 et approche de la version 2.7.

La PLM est constitu e d'exercices, regroup s en le ons et  tendus sur diff rents univers : buggles, turmites, tortues mais aussi listes ou m me simple tests sans interface particuli re. Chaque exer-

cice propose donc un scénario dans ces univers, présentant un nouveau concept à l'utilisateur. Celui-ci doit alors trouver quel code permet de résoudre l'exercice en s'aidant de la démonstration, du texte de mission et de l'API² du monde.

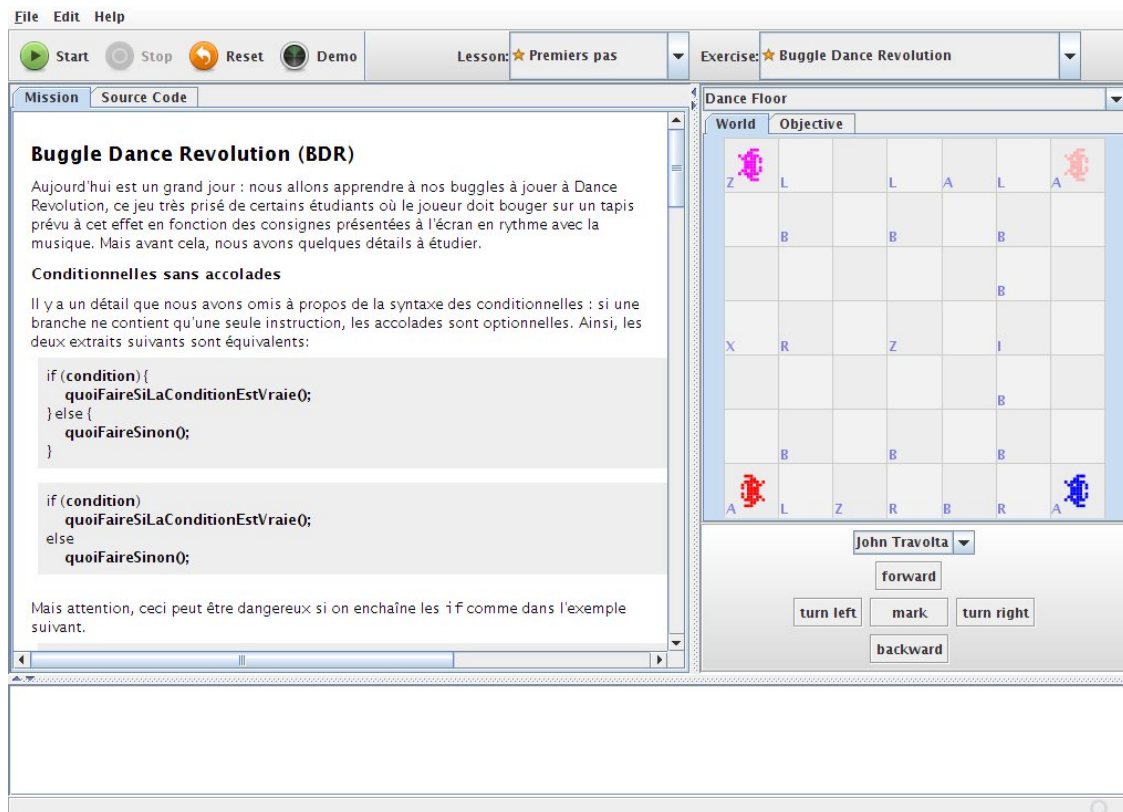


FIGURE 1.2 – Exemple d'exercice : Buggle Dance Revolution, portant sur la lecture d'informations et le pattern matching.

La PLM a été la cible de différents projets au cours du temps, de manière à ajouter des fonctionnalités : langage C, nouveaux exercices et nouvelles leçons et plus récemment aide spécifique à l'utilisateur et aux enseignants.

1.2.2 Portage web de la PLM

En plus des améliorations apportées à la PLM elle-même, il est question depuis décembre 2014 d'un portage AngularJS de l'application. Ce projet, nommé WebPLM, est principalement géré par Matthieu Nicolas. La nouvelle architecture proposée est une interface client utilisant angular.js reliée via une WebSocket à un serveur web tournant sous Play Framework.

De cette manière, il serait en fait possible de centraliser les informations (ce qui permettrait un partage plus facile des améliorations) mais aussi pour permettre à terme de l'intégrer aux MOOC de programmation.

Le portage web de PLM est aujourd'hui à un état utilisable, la plupart des exercices sont disponibles et les rares problèmes restants sont plus de l'ordre du confort visuel (problèmes d'affichage) ou de l'ordre de données non mises à jour.

2. API : Application Program Interface, ensemble des commandes spécifiques au programme. Ici, il s'agit des commandes de l'univers.

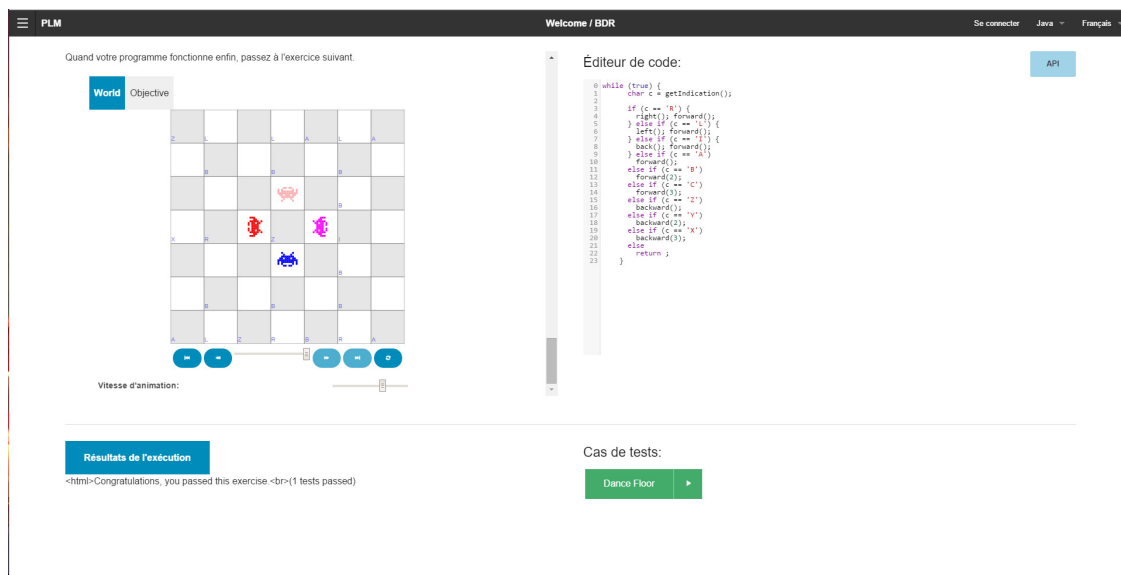


FIGURE 1.3 – Apparence de WebPLM, portage web de la PLM.

2 Problématique du stage

2.1 Contexte du stage

Le portage web entamé récemment portait principalement sur l'interface client et l'utilisation de PLM, sans se soucier des problèmes de performance ou de sécurité. Le projet ayant aujourd'hui atteint un niveau où son déploiement est envisageable, il est nécessaire d'adresser ces deux problèmes.

Pour palier à cela, MM. Quinson, Oster et Nicolas ont envisagé de séparer les deux composantes principales de la PLM : l'environnement d'exécution des exercices et l'environnement d'évolution de l'élève. Cette solution permettrait donc d'isoler l'exécution dans des environnements contrôlés et dont la performance peut être mise à l'échelle.

Cependant, la PLM n'a pas été prévue pour séparer ces deux fonctions, il fallait donc comprendre le code d'origine et mettre en place une stratégie pour le séparer.

2.2 Objectifs du stage

Ce stage avait donc pour objectif de séparer les composantes de compilation/exécution de code élève et de gestion du progrès de l'élève.

Les objectifs du stage ont donc été de :

- Identifier les composantes d'exécution et de gestion de l'élève dans la PLM.
- Créer un outil d'exécution de code
- Utiliser cet outil lors de la demande d'exécution de code
- Rendre l'outil sécurisé et distribuable.
- Améliorer la PLM pour retirer les composantes inutiles

Les pistes proposées par les encadrants de stages étaient de :

- Utiliser une queue de message pour stocker les informations de compilation
- Utiliser la technologie Docker pour rendre le système distribuable.
- Utiliser Docker + un SecurityManager pour sécuriser l'environnement d'exécution.

3 Réalisation

3.1 Environnement de réalisation

La réalisation s'est principalement faite sur un environnement de développement Windows et un environnement d'exécution Linux.

Les technologies utilisées étaient :

Docker

Docker est une technologie de gestion d'applications distribuées. Le principe est de créer des images de machines virtuelles (appelées images docker) qui, une fois lancées, sont directement utilisables avec tous logiciels lancés.

Une telle technologie a pour effet de rendre presque trivial la mise en production et la mise à l'échelle des environnements.

RabbitMQ

Rabbit MQ est un gestionnaire de queue de message. Une queue de message est un système permettant de stocker temporairement des données par "bloc". On peut se connecter à cette queue de message pour y déposer des blocs ou en demander un.

L'idée est que les clients ne s'intéressent pas à qui traite les messages, juste à ce qu'il soit traité.

Play Framework

Play Framework est une application de déploiement de serveur web. Il permet d'installer rapidement un environnement web basé sur une JVM (java ou scala). C'est le système choisi pour développer la version web de la PLM.

En plus de ces technologies, il était nécessaire de créer le modèle de l'application. Il a donc été nécessaire d'appliquer différents designs patterns.

3.2 Méthode de réalisation

3.2.1 Modèle global envisagé

Le modèle de WebPLM au début du stage était assez proche de celui de PLM. En effet, WebPLM "contenait" dans son intégralité Game, le composant principal de PLM. On obtenait donc les figures 3.1 et 3.2 suivantes :

Le but de l'amélioration est de séparer les appels de compilation du serveur. Pour commencer, la modélisation du problème en diagramme de séquence a été réalisée (fig 3.3).

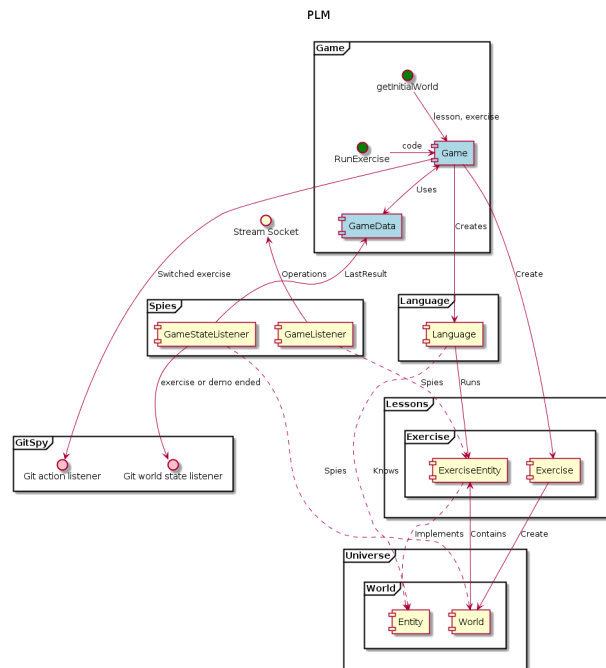


FIGURE 3.1 – Représentation complète de PLM à son exécution

Il a été envisagé dans un premier temps de remplacer les appels de compilation par des appels RMI. Cependant, la technologie RMI de Java n'était pas prévue pour récupérer plus d'un résultat, ce qui posait problème vu que le juge est supposé informer des changements d'états du monde au fur et à mesure de son exécution.

Le modèle envisagé a donc été dans un second temps un gestionnaire de queue de messages, RabbitMQ. Il permettait en effet de distribuer la charge de façon automatique mais aussi de créer automatiquement un protocole de retour dans des queues de messages indépendantes.

3.2.2 Création des juges

Les juges sont de simples conteneurs de la version de PLM déjà présente dans WebPLM. Cependant, ils possèdent une interface leur permettant de communiquer avec une queue de message.

La création des juges permet également de mettre en place des tests automatiques de compilation, nécessaire lorsque WebPLM n'était pas encore à jour. Les tests sont toujours en place dans les juges et permettent encore de tester la viabilité des changements de code sur des exercices simples et plus complexes.

Cette étape a duré approximativement deux jours, terminée le 26-06.

3.2.3 Utilisation des juges

Dans un second temps, il était nécessaire de refabriquer l'étape de compilation de WebPLM. Pour cela, il a fallu dans un premier temps écrire la structure d'appel et de récupération depuis la queue de message, puis de reformater le code de manière à le rendre utilisable.

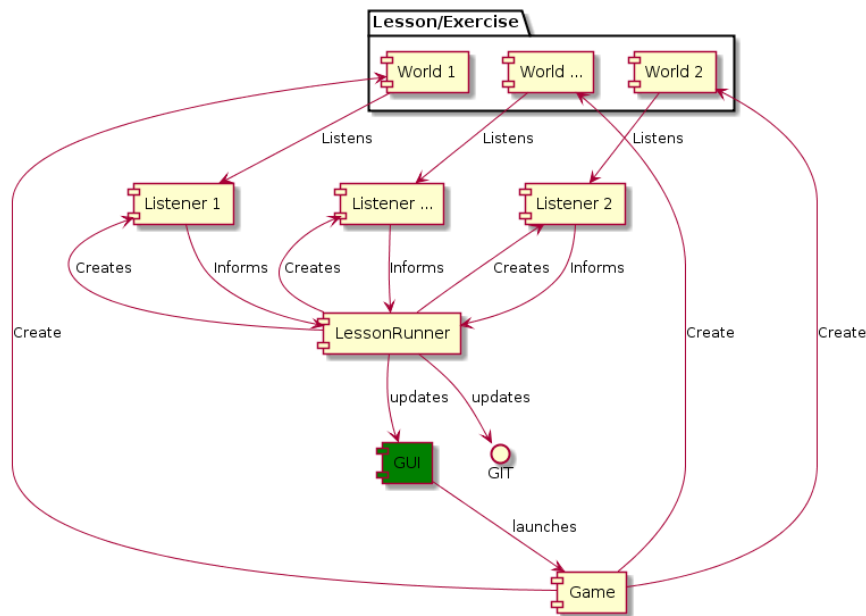


FIGURE 3.2 – Représentation simplifiée de WebPLM au début du stage

Système de base

Tout d'abord, il a fallu écrire un système de base permettant à WebPLM d'utiliser la message queue pour gérer les appels de compilation et d'en récupérer les résultats pour les transmettre au client.

L'étape d'écriture du code a pris environ 3 jours, terminée le 01-07. A ce moment, WebPLM utilisait déjà des juges parallélisables pour la compilation.

Stockage du résultat

Il fallait ensuite réécrire les appels au gestionnaire GIT de manière à enregistrer la progression de l'élève ainsi que son code. Il a été nécessaire d'extraire le gestionnaire du Game toujours présent dans WebPLM et de l'utiliser à partir de là.

Cette étape a duré deux autres jours, terminée le 03-07.

Analyses de performances, limites d'exécution, arrêt automatique

Enfin, il a fallu tester les performances et adapter le résultat en conséquence.

La première version avait d'énormes problèmes de performance. Cela était dû au fait que la queue de messages contenait un message par opération du monde, message générés en parallèle qui plus est. J'ai donc mis en place un accumulateur au niveau des listeners (cf figure 3.2) pour n'envoyer qu'une opération toutes les 500ms. Cela a résolu le problème de performance de base.

Il y avait également un problème de stabilité lors de compilations se terminant en boucle infinie. Pour gérer cela, il a été mis en place un système de sémaphore avec tentative d'acquisition pendant X secondes (X allait 30s, puis 15, puis 10 au fur et à mesure du projet), sémaphore réveillée par

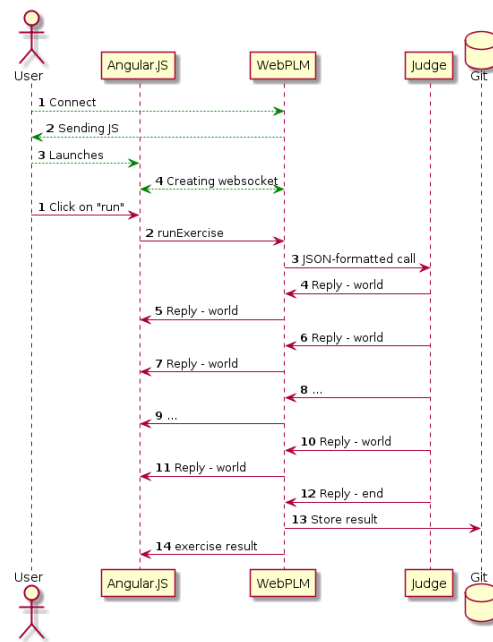


FIGURE 3.3 – Diagramme de séquence du problème. En vert est l'étape de connexion, déjà créée dans WebPLM au moment du stage

les listeners lors de la fin d'exécution.

Le résultat final était donc une version de PLM stable, décrite en figure 3.4.

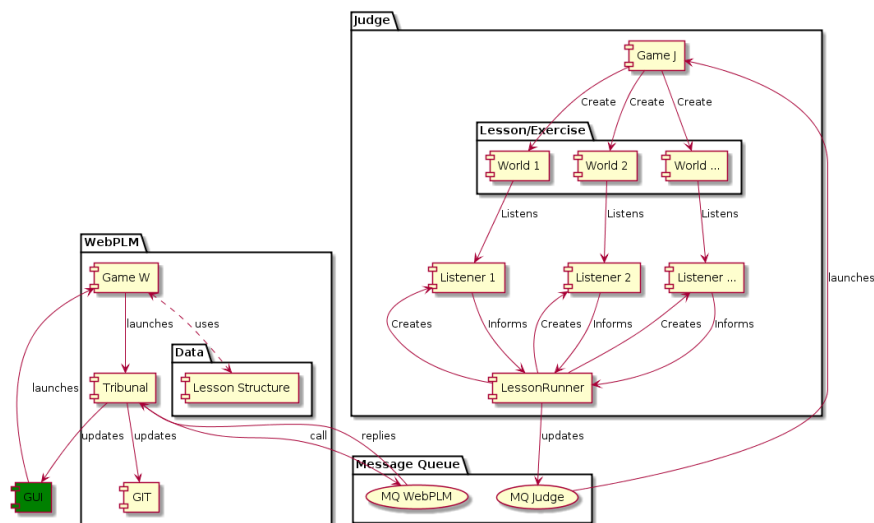


FIGURE 3.4 – Structure simplifiée de WebPLM et juges à la fin de l'étape de création des juges.

3.2.4 Etude d'un mode debug

Pendant les semaines suivantes du stage, il a été question d'un mode "debug" de PLM. Ce mode debug devait permettre aux élèves d'avoir un aperçu de l'évolution de leurs variables et au système d'enseignement de détecter des schémas plus précis où l'élève resterait bloqué.

Différentes solutions ont été étudiées au cours du stage, en particulier la librairie JDI de Java pour

détecter les modifications sur l'autre machine. Cependant, ce projet n'a jamais eu la priorité qu'il aurait fallu pour le mener à terme.

3.2.5 Utilisation de Docker

Après avoir modifié WebPLM pour se comporter en deux parties, il a été nécessaire d'adapter ces deux parties pour qu'elles puissent être utilisées dans des containers Docker.

Les principaux défis de cette étape n'ont pas été la réalisation elle-même mais la compréhension des différents problèmes rencontrés.

Interaction entre Docker et Maven

Docker et Maven sont deux outils ayant des propriétés similaires : la centralisation des données en vue d'une utilisation déployable facilement. Le principal souci rencontré est lors de la génération des images Docker, Maven devant télécharger à chaque fois l'intégralité des composants. Le résultat était une compilation à réussite aléatoire.

Déploiement de RabbitMQ et utilisations de variables internes

Les différents composants de WebPLM avaient tous besoin d'un outil commun : la connaissance de l'adresse de la Message Queue. Il a fallu modifier WebPLM et les juges de manière à pouvoir récupérer ces informations automatiquement.

Cette étape aura duré du 09/07 au 16/07.

3.2.6 Documentation du code existant

Une phase de documentation et de refactoring a alors pris place. Maintenant que tous les composants étaient mis en place, il était possible de refabriquer les structures de données de manière à les adapter au mieux aux tâches qu'elles devaient résoudre. Une javadoc des ajouts déjà effectués a été également réalisée de manière à rendre plus facile toute modification subséquente du code.

Cette étape s'est étendue sur les 20 et 21 juillet.

3.2.7 Ajout d'opérations de logging

Une étape de l'amélioration du projet WebPLM a été de rajouter l'affichage du canal de sortie standard sur l'écran de l'utilisateur. Pour cela, il a fallu capturer toutes les données de sortie standard et les rediriger en tant qu'opérations vers l'utilisateur. Il a également fallu recréer un canal spécifique permettant aux logs de l'application de tout de même apparaître sur la sortie standard.

Cette étape a pris place les 22/07 et 23/07.

3.2.8 Standardisation des données

Un problème assez particulier nous est apparu. Pour certains mondes, le code de résolution était entré et un juge validait le résultat, cependant l'affichage sur la WebPLM paraissait faux.

Il s'avère que la génération de certains mondes était aléatoire, ce qui provoquait une discordance entre les actions calculées à partir du monde du juge et celles appliquées sur le monde affiché. Il a donc fallu standardiser les mondes.

Pour cela, il a été appliqué une méthode simple : les fonctions aléatoires ont vu leur "seed" se faire fixer au même nombre. Selon la Javadoc, les résultats sont donc maintenant strictement identiques quelque soit le système utilisé.

Cela a été effectué le 24/07.

3.2.9 Pré-génération des données

En vue du passage à une version de WebPLM (côté serveur) sans la composante PLM, il fallait générer les données nécessaires (structures des exercices, état initial des mondes, démonstrations) et les stocker de façon statique avant de pouvoir juste supprimer Game.

Pour arriver à ce résultat, il a fallu modifier un juge pour lui faire parcourir tous les exercices et, pour chacun, générer la démonstration et l'état initial.

Cette étape a été effectuée du 27/07 au 05/08

3.2.10 Nettoyage de la PLM

La dernière étape de ce stage a été de tenter de retirer PLM (en particulier Game) de WebPLM. Pour cela, il fallait étudier les différentes composantes utiles de PLM, les réécrire au mieux pour Play Framework (en Scala) et résoudre les différents problèmes de taille mémoire et de concurrence qui apparaissaient.

Au début de cette étape, la structure de PLM était celle présentée en figure 3.5.

Le but était d'obtenir une structure telle que celle en 3.6.

Les principales étapes de ce nettoyage ont été de retirer la composante de lecture de données, les missions (textes d'informations sur les exercices) et les APIs (textes d'informations sur les mondes), la composante de localisation ainsi que celle de gestion du langage de programmation. Il a fallu également convertir les fonctions de génération en fonction de lecture ou d'exposition : les démonstrations sont par exemple pré-générées et exposées en tant que fichiers par le serveur et c'est le client qui va les chercher pour les afficher, ce qui améliore énormément les performances du serveur.

Cependant, il reste un grand nombre de fonctions non converties : gestion du changement de leçon, d'exercice et de langue (naturelle/programmation), sauvegarde des données sur le gestionnaire GIT.

Cette tâche, commencée le 06/08, continue encore aujourd'hui.

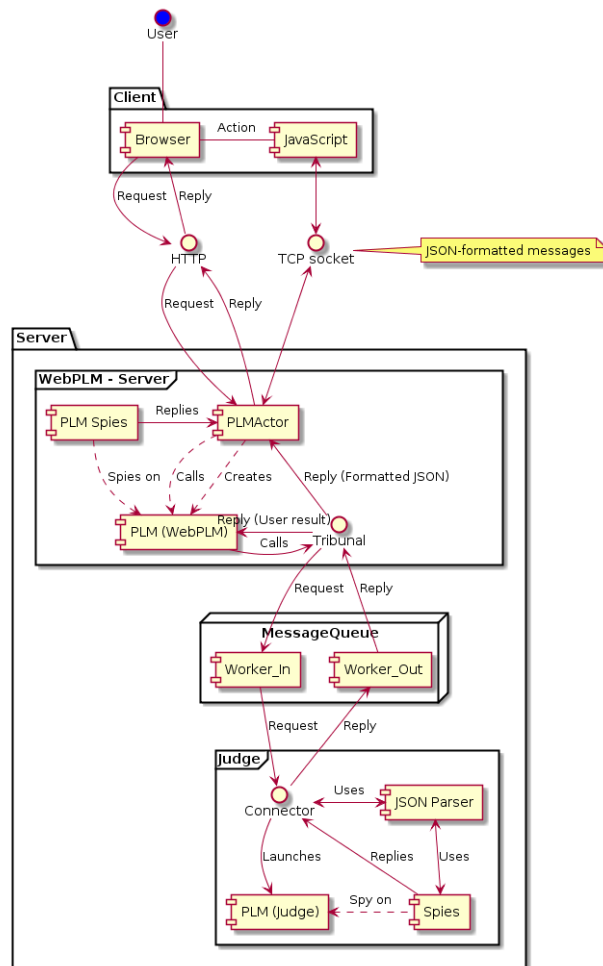


FIGURE 3.5 – Structure de WebPLM au début du nettoyage

3.2.11 Mise en place d'un Security Manager

Vers la fin de la période, nous nous sommes rendu compte que de nombreuses failles de sécurité que Docker était censé résoudre ne l'étaient en fait pas : accès à l'internet depuis un container, surcharge du processeur et surcharge du disque dur.

Pour résoudre certains de ces problèmes, nous avons utilisé un outil rendu disponible par Java, le Security Manager. Il permet de limiter les actions possibles pour chaque composante de l'application.

Nous avons donc limité les actions disponibles à l'utilisateur, en lui interdisant toute communication avec l'extérieur du programme. Il restait tout de même plusieurs problèmes potentiels mais le résultat est qu'aucun de ces problèmes ne risque de briser la sécurité du système.

3.3 Résultats obtenus

3.3.1 Modèle final

Le modèle final de WebPLM est donc celui présenté en 3.7

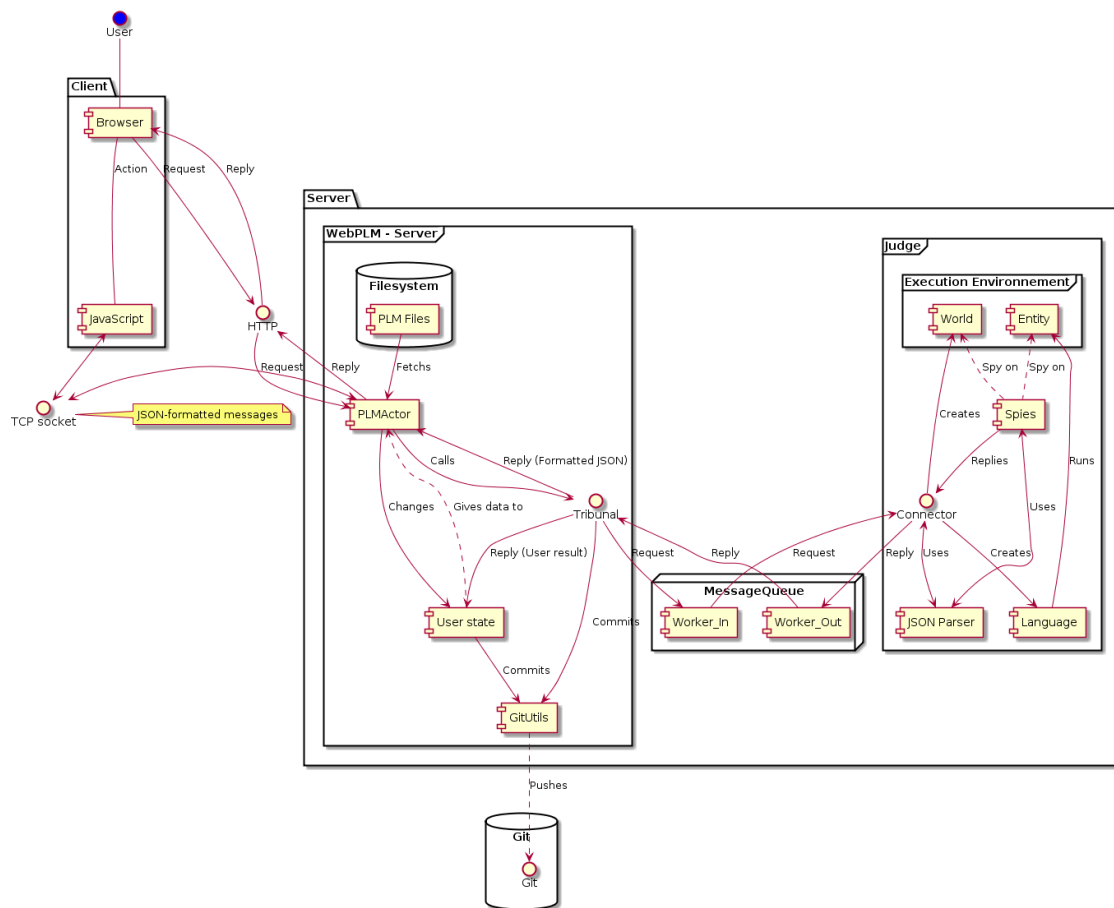


FIGURE 3.6 – Structure finale idéale de WebPLM.

C'est effectivement la même structure qu'avant le nettoyage, à raison : au moment de l'écriture de ce rapport, l'opération de séparation des composants de Game n'est pas terminée et ne le sera probablement pas avant la fin du stage.

3.3.2 Apports

Cependant, un certain nombre d'apports ont été faits à PLM au cours de ce stage.

Dans un premier temps, l'objectif principal de séparer composantes d'exécution et de gestion est accompli.

Il a été également rajouté des fonctions auxiliaires utiles : gestion de la sortie d'affichage standard, suppression des composantes aléatoires des exercices.

De gros progrès ont été également apportés sur l'étape de retrait de PLM depuis WebPLM.

Enfin, un travail de défrichage a été fait sur le mode debug.

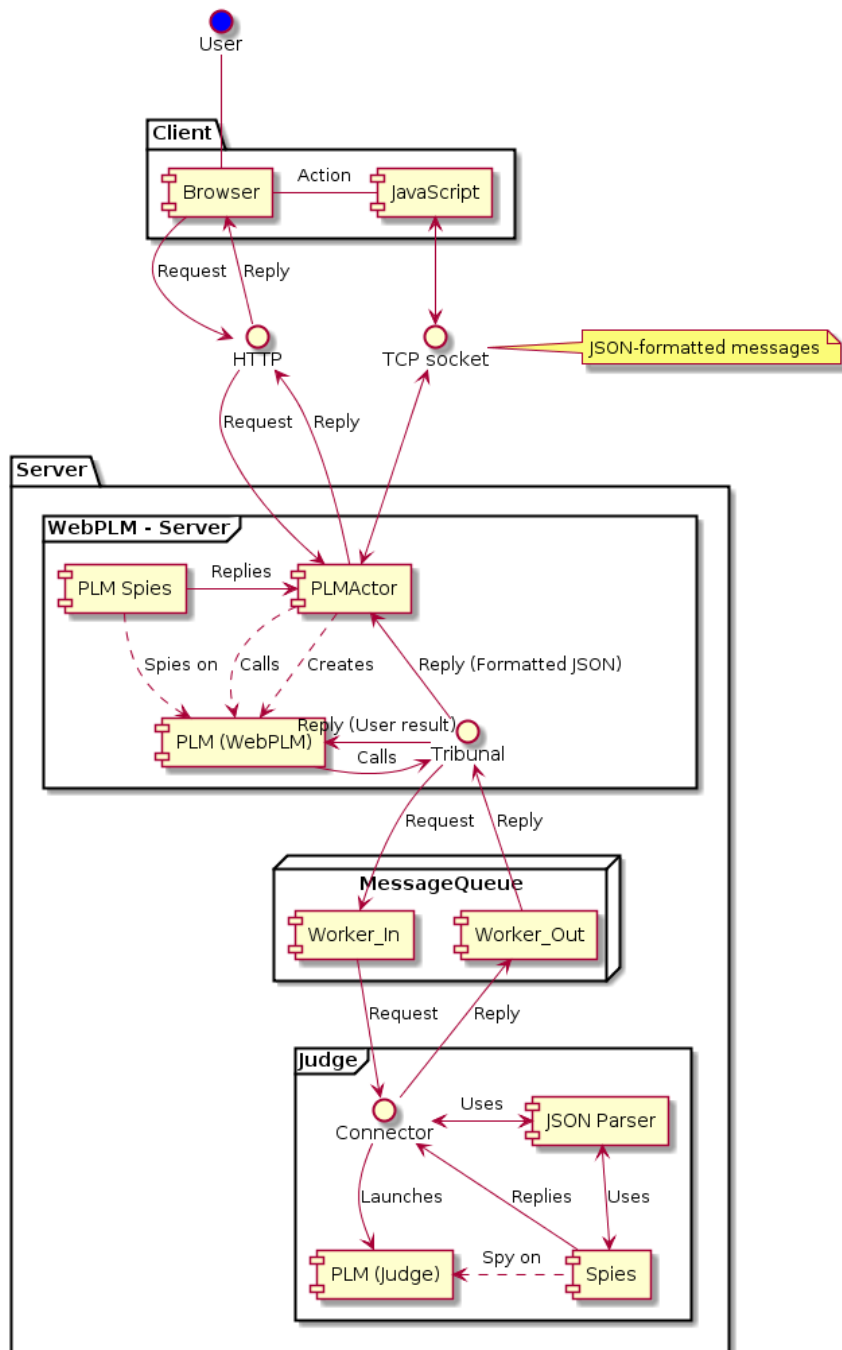


FIGURE 3.7 – Structure de WebPLM a la fin du stage.

4 Résultats

4.1 Bilan

Les réalisations lors de ce stage ont été conformes

4.2 Améliorations prévues

4.3 Améliorations possibles

Résumé

Mots-clés :

Abstract

Keywords :